IMPLEMENTASI PIPELINE DATA AWS UNTUK ANALISIS ULASAN GOJEK TERHADAP RATING DRIVER

Disusun oleh:

Kelompok 7

Nama anggota:

Diah Anggraini	24083010051
Diva Anggraeni	24083010065
Fatma Novalia Kussumarani	24083010098

SUMBER DATA

Gojek App Reviews Bahasa Indonesia dari Kaggle (format CSV) yang beisi informasi ulasan pengguna aplikasi Gojek.
Tautan: https://www.kaggle.com/datasets/ucupsedaya/gojek-app-reviews-bahasa-indonesia

DESKRIPSI DATASET

Total data: 225.002 data
Variabel: userName, content, score, at, dan appVersion

Variabel yang digunakan:

- Content : teks ulasan pengguna
- Score : rating yang diberikan pengguna (skala 1-5)
- At : waktu pengguna memberikan ulasan

ARSITEKTUR

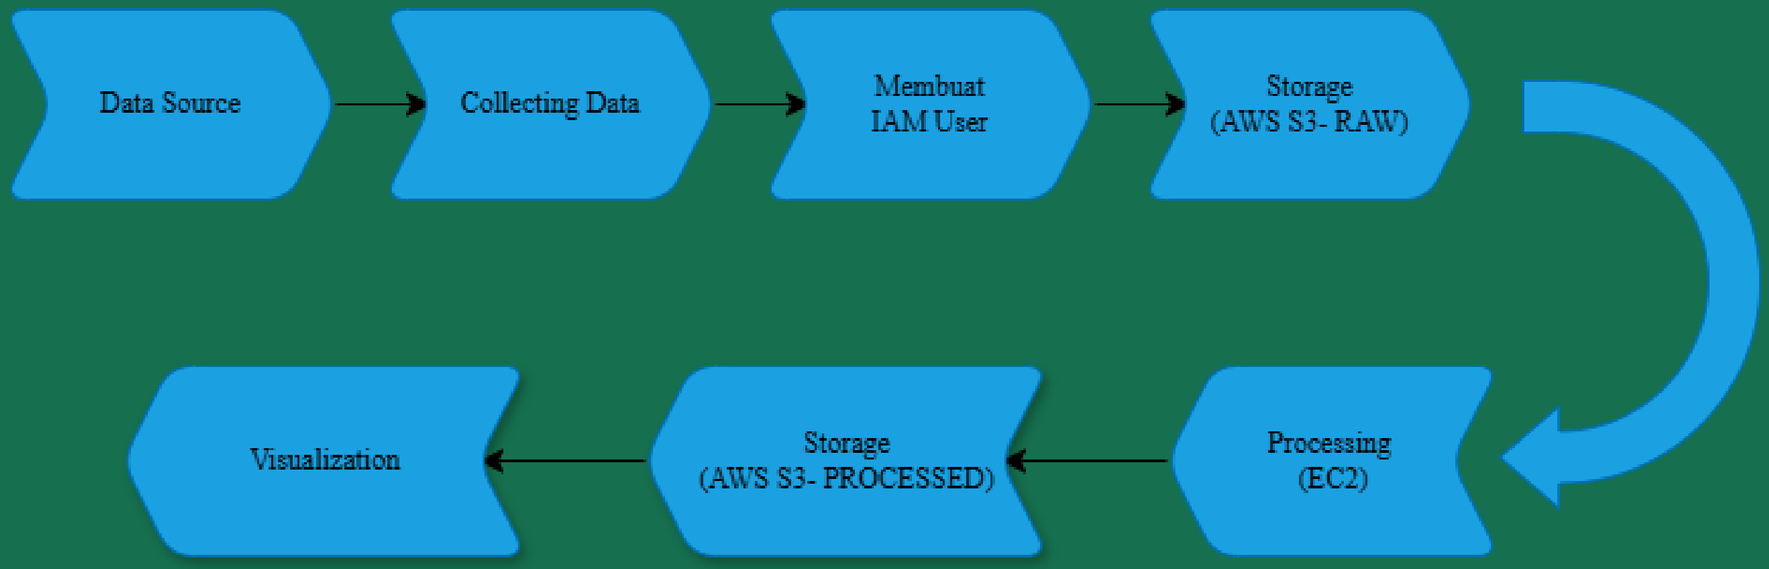
Data Source
Collecting Data
Membuat
IAM User
Storage
(AWS S3- RAW)
Processing
(EC2)
Storage
(AWS S3- PROCESSED)
Visualization

LOADING DATASET

```python
import pandas as pd

df = pd.read_csv("Gojek App Review.csv")

print(df.head())
print(df.info())
```

```
                 userName                                            content  \
0               Yuga Edit                            akun gopay saya di blok
1                ff burik  Lambat sekali sekarang ini bosssku apk gojek g...
2  Anisa Suci Rahmayuliani  Kenapa sih dari kemarin sy buka aplikasi gojek...
3            naoki yakuza  Baru download gojek dan hape baru trus ditop u...
4           Trio Sugianto                                             Mantap

   score                  at appVersion
0      1  2022-01-21 10:52:12      4.9.3
1      3  2021-11-30 15:40:38      4.9.3
2      4  2021-11-29 22:58:12      4.9.3
3      1  2022-09-03 15:21:17      4.9.3
4      5  2022-01-15 10:05:27      4.9.3
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 225002 entries, 0 to 225001
Data columns (total 5 columns):
 #   Column      Non-Null Count   Dtype
---  ------      --------------   -----
 0   userName    225002 non-null  object
 1   content     225000 non-null  object
 2   score       225002 non-null  int64
 3   at          225002 non-null  object
 4   appVersion  225002 non-null  object
dtypes: int64(1), object(4)
memory usage: 8.6+ MB
None
```

Dataset berhasil dimuat dengan total 225.002 data. Output tampilan 5 data awal, struktur data, serta adanya missing value pada variabel content karena jumlah datanya tidak lengkap.

CLEANING DASAR

1. Pemilihan kolom yang relevan

```
# AMBIL KOLOM YANG DIPERLUKAN
df = df[['content', 'score', 'at']]
df.head()
```

	content	score	at
0	akun gopay saya di blok	1	2022-01-21 10:52:12
1	Lambat sekali sekarang ini bosssku apk gojek g...	3	2021-11-30 15:40:38
2	Kenapa sih dari kemarin sy buka aplikasi gojek...	4	2021-11-29 22:58:12
3	Baru download gojek dan hape baru trus ditop u...	1	2022-09-03 15:21:17
4	Mantap	5	2022-01-15 10:05:27

2. Konversi dan ekstraksi data waktu

```
# MENGATASI TANGGAL DAN WAKTU
#--- Ubah ke datetime ---
df['at'] = pd.to_datetime(df['at'], errors='coerce')
print(df['at'].dtype)

#--- Ambil tanggalnya saja ---
df['date'] = df['at'].dt.normalize()
df.head()
```

datetime64[ns]

	content	score	at	date
0	akun gopay saya di blok	1	2022-01-21 10:52:12	2022-01-21
1	Lambat sekali sekarang ini bosssku apk gojek g...	3	2021-11-30 15:40:38	2021-11-30
2	Kenapa sih dari kemarin sy buka aplikasi gojek...	4	2021-11-29 22:58:12	2021-11-29
3	Baru download gojek dan hape baru trus ditop u...	1	2022-09-03 15:21:17	2022-09-03
4	Mantap	5	2022-01-15 10:05:27	2022-01-15

3. Penghapusan kolom yang tidak digunakan

```
# HAPUS KOLOM 'AT'
df = df.drop(columns='at')
```

CLEANING DASAR

4. Perubahan nama kolom

```
# RERNAME KOLOM
df = df.rename(columns={'content': 'review', 'score': 'rating'})
df.head()
```

	review	rating	date
0	akun gopay saya di blok	1	2022-01-21
1	Lambat sekali sekarang ini bosssku apk gojek g...	3	2021-11-30
2	Kenapa sih dari kemarin sy buka aplikasi gojek...	4	2021-11-29
3	Baru download gojek dan hape baru trus ditop u...	1	2022-09-03
4	Mantap	5	2022-01-15

5. Pengecekan dan penanganan missing value

```
# CEK MISSING VALUE DAN SOLUSI
print("=== Missing Value Sebelum Cleaning ===")
print(df.isnull().sum())

## SOLUSI ##
df = df.dropna(subset=['review', 'rating', 'date'])
print("\n=== Missing Value Sesudah Cleaning ===")
print(df.isnull().sum())

print(df.info())
```

```
=== Missing Value Sebelum Cleaning ===
review    2
rating    0
date      0
dtype: int64

=== Missing Value Sesudah Cleaning ===
review    0
rating    0
date      0
dtype: int64
<class 'pandas.core.frame.DataFrame'>
Index: 225000 entries, 0 to 225001
Data columns (total 3 columns):
 #   Column  Non-Null Count   Dtype
---  ------  --------------   -----
 0   review  225000 non-null  object
 1   rating  225000 non-null  int64
 2   date    225000 non-null  datetime64[ns]
dtypes: datetime64[ns](1), int64(1), object(1)
```

6. Standarisasi kapital

```
# STANDARISASI KAPITAL PADA TEXT REVIEW
df['review'] = df['review'].str.lower()
```

CLEANING DASAR

7. Pengecekan dan penghapusan data duplikat

```python
# CEK DUPLIKASI DATA
print("Jumlah Awal Duplikat:", df.duplicated().sum())
print("Duplikasi Data Sebelum Cleaning:", len(df))

df = df.drop_duplicates()

print("\nJumlah Akhir Duplikat:", df.duplicated().sum())
print("Duplikasi Data Sesudah Cleaning:", len(df))
```

```
Jumlah Awal Duplikat: 40178
Duplikasi Data Sebelum Cleaning: 225000

Jumlah Akhir Duplikat: 0
Duplikasi Data Sesudah Cleaning: 184822
```

8. Filtering data berdasarkan kata kunci

```python
# FILTERING KEYWORD 'driver', 'kurir'
df = df[df['review'].str.contains('driver|kurir', case=False, na=False)]
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 16957 entries, 10 to 224980
Data columns (total 3 columns):
 #   Column  Non-Null Count  Dtype
---  ------  --------------  -----
 0   review  16957 non-null  object
 1   rating  16957 non-null  int64
 2   date    16957 non-null  datetime64[ns]
dtypes: datetime64[ns](1), int64(1), object(1)
memory usage: 529.9+ KB
```

9. Penyimpanan data hasil preprocessing

```python
# SIMPAN CLEAN DATA
df.to_csv("gojek_review_clean.csv", index=False)
```

DATA PROCESSING DENGAN EC2

SETUP EC2

Launch instance

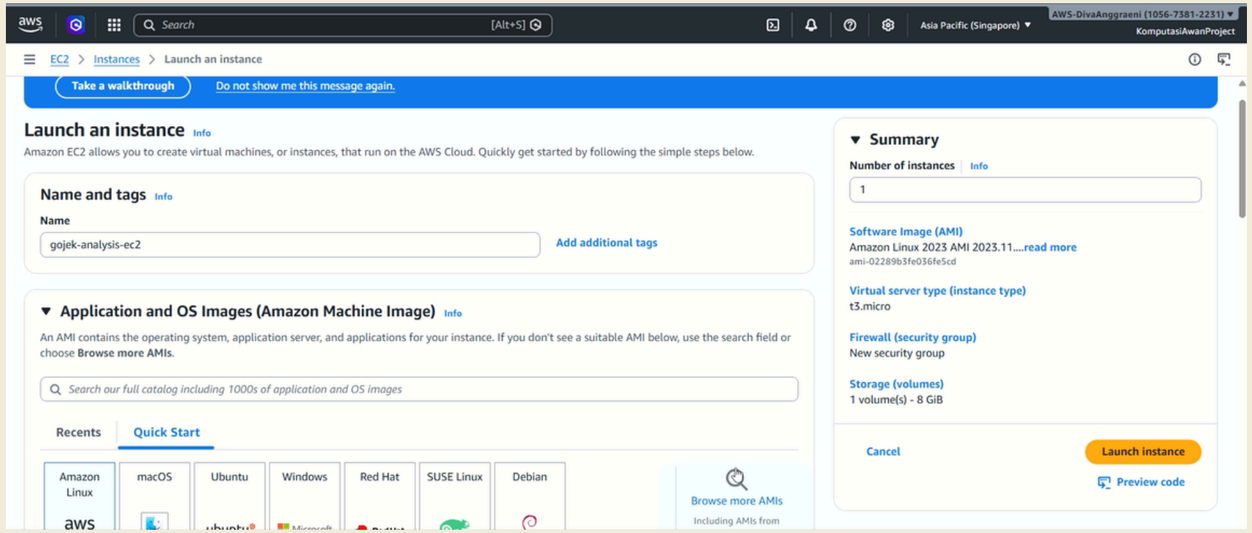

Key pair

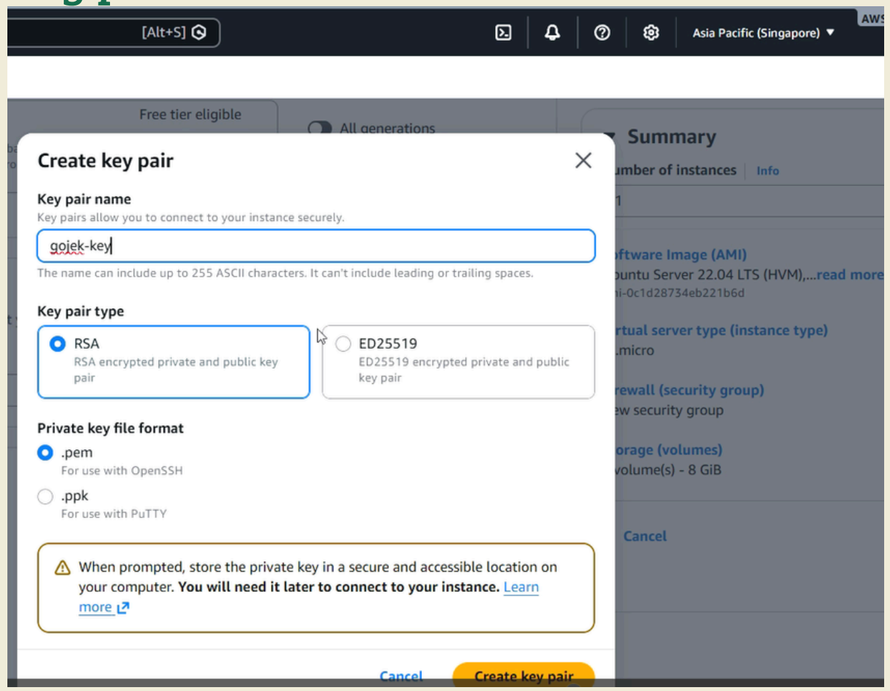

Tahap pertama dilakukan pembuatan instance EC2 di AWS sebagai server virtual dengan konfigurasi Ubuntu 22.04, tipe t2.micro, serta pengaturan key pair dan security group untuk mengakses Jupyter Notebook melalui port 8888.

DATA PROCESSING DENGAN EC2

AKSES JUPYTER NOTEBOOK

Koneksi SSH ke server

```
ubuntu@ip-172-31-13-124:~$ jupyter notebook --ip=0.0.0.0 --port=8888 --no-browser --allow-root
[I 2026-04-14 04:20:23.601 ServerApp] jupyter_lsp | extension was successfully linked.
[I 2026-04-14 04:20:23.606 ServerApp] jupyter_server_terminals | extension was successfully linked.
[I 2026-04-14 04:20:23.611 ServerApp] jupyterlab | extension was successfully linked.
[I 2026-04-14 04:20:23.616 ServerApp] notebook | extension was successfully linked.
[I 2026-04-14 04:20:23.925 ServerApp] notebook_shim | extension was successfully linked.
[I 2026-04-14 04:20:23.941 ServerApp] notebook_shim | extension was successfully loaded.
[I 2026-04-14 04:20:23.945 ServerApp] jupyter_lsp | extension was successfully loaded.
[I 2026-04-14 04:20:23.946 ServerApp] jupyter_server_terminals | extension was successfully loaded.
[I 2026-04-14 04:20:23.949 LabApp] JupyterLab extension loaded from /home/ubuntu/.local/lib/python3.10/site-packages/jupyterlab
[I 2026-04-14 04:20:23.949 LabApp] JupyterLab application directory is /home/ubuntu/.local/share/jupyter/lab
[I 2026-04-14 04:20:23.949 LabApp] Extension Manager is 'pypi'.
[I 2026-04-14 04:20:24.019 ServerApp] jupyterlab | extension was successfully loaded.
[I 2026-04-14 04:20:24.024 ServerApp] notebook | extension was successfully loaded.
[I 2026-04-14 04:20:24.024 ServerApp] Serving notebooks from local directory: /home/ubuntu
[I 2026-04-14 04:20:24.025 ServerApp] Jupyter Server 2.17.0 is running at:
[I 2026-04-14 04:20:24.025 ServerApp] http://ip-172-31-13-124:8888/tree?token=8fce2cba230201edc844f568e53751ab274a1b15e4fd854f
[I 2026-04-14 04:20:24.025 ServerApp]     http://127.0.0.1:8888/tree?token=8fce2cba230201edc844f568e53751ab274a1b15e4fd854f
[I 2026-04-14 04:20:24.025 ServerApp] Use Control-C to stop this server and shut down all kernels (twice to skip confirmation).
[C 2026-04-14 04:20:24.028 ServerApp]

    To access the server, open this file in a browser:
        file:///home/ubuntu/.local/share/jupyter/runtime/jpserver-3972-open.html
    Or copy and paste one of these URLs:
        http://ip-172-31-13-124:8888/tree?token=8fce2cba230201edc844f568e53751ab274a1b15e4fd854f
        http://127.0.0.1:8888/tree?token=8fce2cba230201edc844f568e53751ab274a1b15e4fd854f
```

Tampilan Jupyter di browser

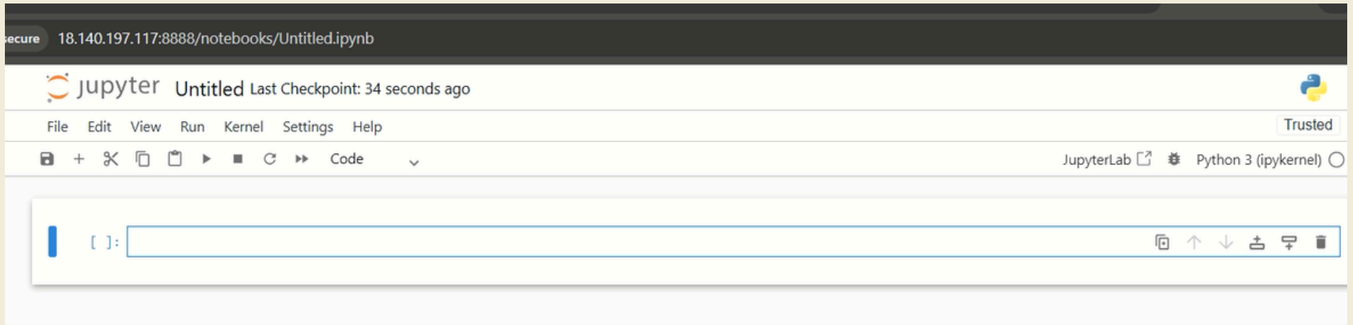

Setelah instance dibuat, dilakukan koneksi SSH ke server dan instalasi Python beserta library pendukung untuk analisis data. Selanjutnya, Jupyter Notebook dijalankan di EC2 dan diakses melalui browser menggunakan IP publik dengan autentikasi token.

DATA PROCESSING DENGAN EC2

AKSES DATASET DARI S3

Akses ke S3 dilakukan menggunakan library boto3 dengan memasukkan access key, secret key, nama bucket, dan lokasi file (key) untuk menghubungkan Python ke AWS S3. Setelah koneksi berhasil, dataset dalam format CSV diambil dan dibaca menggunakan pandas menjadi dataframe.

```python
import boto3
import pandas as pd
from io import StringIO

s3 = boto3.client(
    's3',
    aws_access_key_id='AKIARRGVGNEDW52ODK72',
    aws_secret_access_key='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',
    region_name='ap-southeast-1'
)

bucket = '51.65.98-gojek.review-bucket'
key = 'processed/gojek_review_clean.csv'

response = s3.get_object(Bucket=bucket, Key=key)

df = pd.read_csv(StringIO(response['Body'].read().decode('utf-8')))

df.head()
```

	review	rating	date
0	kumpulan driver sampah	1	2023-08-23
1	makin lama gojek makin ngga jelas susah bgt da...	1	2022-05-08
2	gojek akhir2 ini ngeselin driverny suka cancel...	3	2022-01-13
3	banyak maling dari driver gosend kurir sialan ...	1	2022-01-20
4	driver untuk area malang tolong di tambah musi...	5	2022-01-24

DATA PROCESSING DENGAN EC2

PROSES ANALISIS

Kategori Kepuasan Pengguna

No	Kategori	Jumlah
1	Tidak Puas	9734
2	Puas	5913
3	Netral	1310

Dari hasil tersebut dapat disimpulkan bahwa sebagian besar pengguna memberikan penilaian Tidak Puas, sehingga tingkat kepuasan pengguna masih tergolong rendah dan menunjukkan adanya aspek layanan yang perlu ditingkatkan.

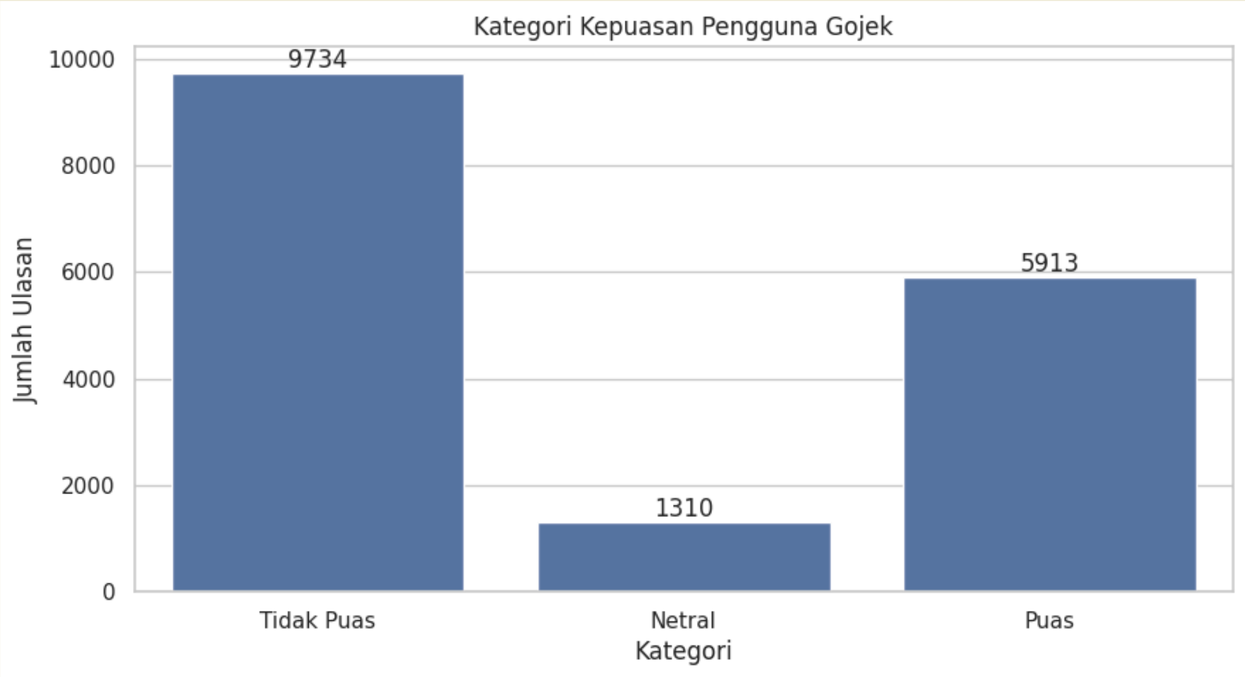

DATA PROCESSING DENGAN EC2

PROSES ANALISIS

Distribusi Rating Pengguna

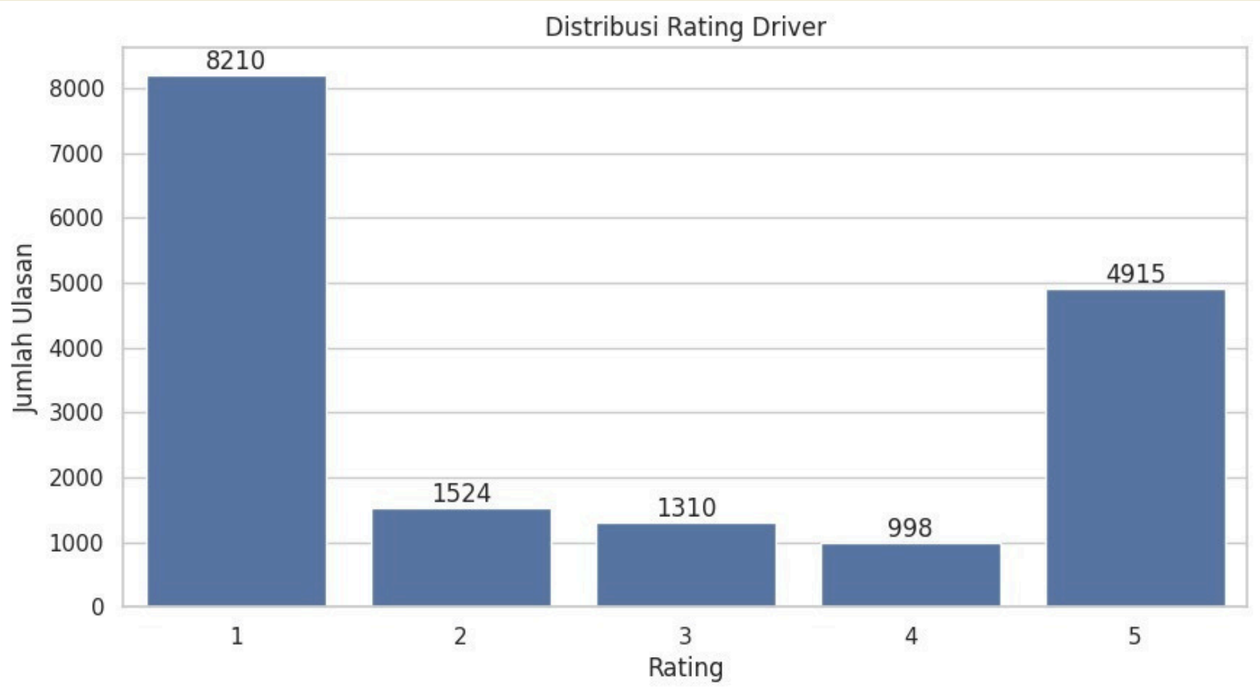

Rating	Jumlah Ulasan
1	8210
2	1524
3	1310
4	998
5	4915

hasil menunjukkan rating 1 mendominasi jumlah ulasan, menunjukkan banyak pengguna memberikan penilaian rendah, meskipun rating 5 juga cukup tinggi.

DATA PROCESSING DENGAN EC2

PROSES ANALISIS

Rata-rata rating per bulan

year_month	Rating
2021-11	2,27
2021-12	2,27
2022-01	2,71
2022-02	2,7
2022-03	2,97
2022-04	2,64
2022-05	1,97
2022-06	3,43
2022-07	3,06
2022-08	3,0
2022-09	2,88
2022-10	2,84
2022-11	2,59
2022-12	2,74
2023-01	2,7
2023-02	2,82
2023-03	2,42
2023-04	2,19
2023-05	2,33
2023-06	2,69
2023-07	2,7
2023-08	2,59
2023-09	2,49
2023-10	2,49
2023-11	2,31
2023-12	2,09
2024-01	2,35
2024-02	2,32

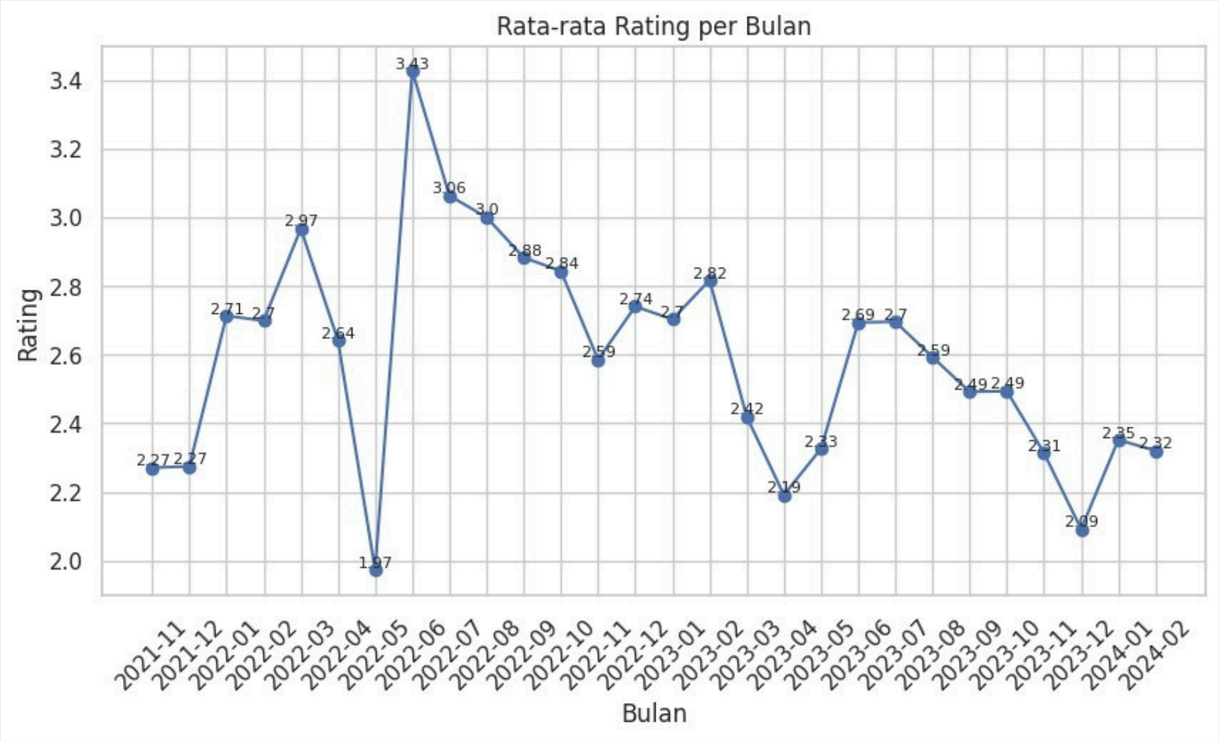

Rata-rata rating cenderung fluktuatif dan berada pada nilai rendah, yang menunjukkan konsistensi tingkat kepuasan pengguna yang belum optimal sepanjang waktu.

DATA PROCESSING DENGAN EC2

PROSES ANALISIS

Top 3 ulasan rating 1 dan rating 5

Hasil analisis menunjukkan bahwa pada ulasan dengan rating 1 umumnya berisi keluhan terhadap layanan, seperti keterlambatan, ketidsesuaian layanan, atau pengalaman negatif lainnya. Sedangkan, ulasan dengan rating 5 umumnya berisi apresiasi terhadap kemudahan pengguunaa aplikasi dan kualitas layanan yang baik.

Tabel 3.4. Top 3 Ulasan Rating Ekstrem

TOP	Rating 1	Rating 5
1	ajarin driver sop untuk ramah ke pelanggan dari awal pick up muka udh jutek oke saya b aja pas jln nya pelan pdhl saya udh mintol dgn sopan pak maaf jln nya bsa cepet gk saya dah telat tpi dia jawab ketus oke saya msh sabar pas di jln saya di salahin sama driver nya mba harus nya tau dong lokasi nya dmna kan jadi nya nyasar hello gua naik ojol tuh emang gk tau alamat nya trs ngapain gua naik ojol kalo gua yg harus cari tau alamat nya padahal udh tag alamat sesuai tujuan	review_length sy sering menggunakan go ride dan kendala yang saya alami adalah menunggu driver rumah sy di daerah kota yang sangat gampang dan cepat sekali mendapatkan driver dan sy byasa menuju ke daerah pinggiran kota yang jarang driver dan keperluan sy hanya 10menit kembali lagi ke rumah saat sy order untuk kembali pasti lama sekali dapat driver padahal driver yang sy tumpangi tadi masih ada di depan saya saran saya adakan paket pp pulang pergi jd kami sebagai customer gak kelamaan nunggu driver lain kata drivernya gak boleh nrima order orang yang sama pada hari yang sama

VISUALISASI

Tren Kepuasan Pengguna per Bulan

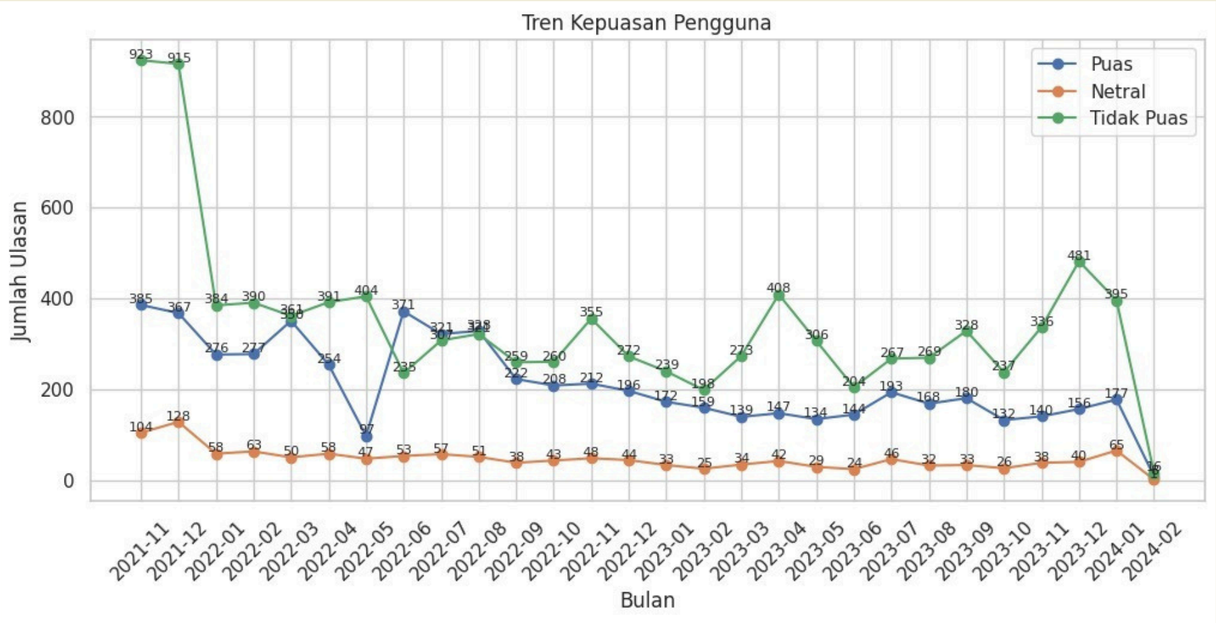

Jumlah pengguna tidak puas cenderung lebih tinggi dibanding kategori lainnya di hampir setiap bulan, meskipun terjadi fluktuasi pada semua kategori kepuasan.

VISUALISASI

WordCloud Ulasan Rating 1

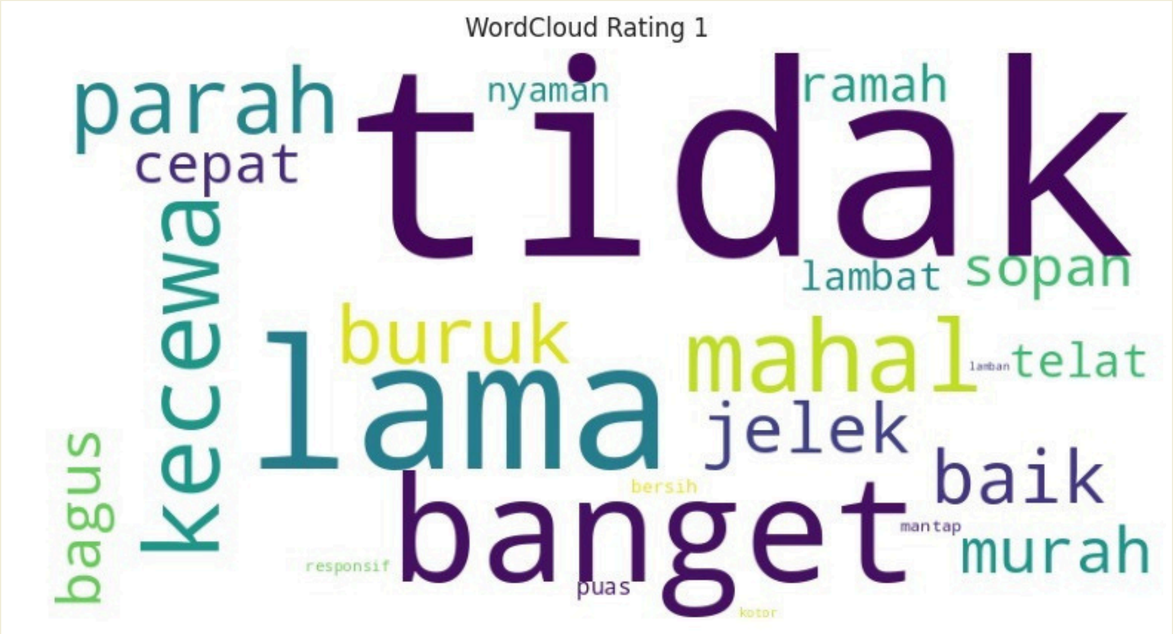

Ulasan rating rendah didominasi kata-kata bernuansa negatif seperti tidak, lama, kecewa, dan buruk, yang mencerminkan ketidakpuasan pengguna terhadap layanan.

WordCloud Ulasan Rating 5

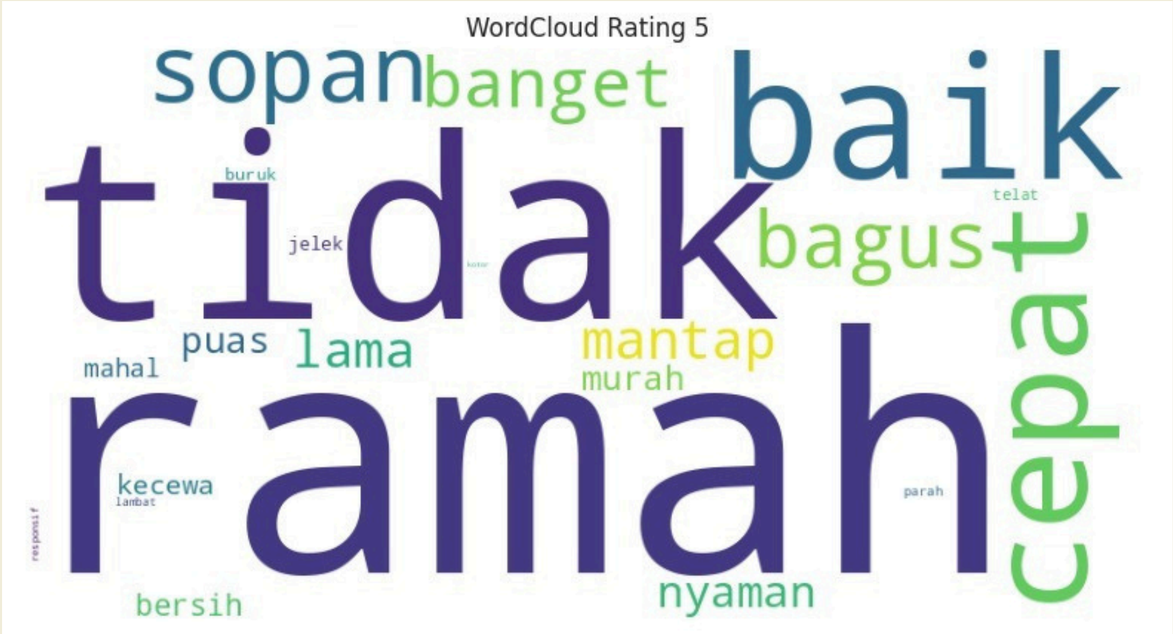

Ulasan rating tinggi didominasi kata-kata positif seperti ramah, baik, cepat, dan bagus, yang menunjukkan kepuasan pengguna terhadap performa layanan, khususnya driver.

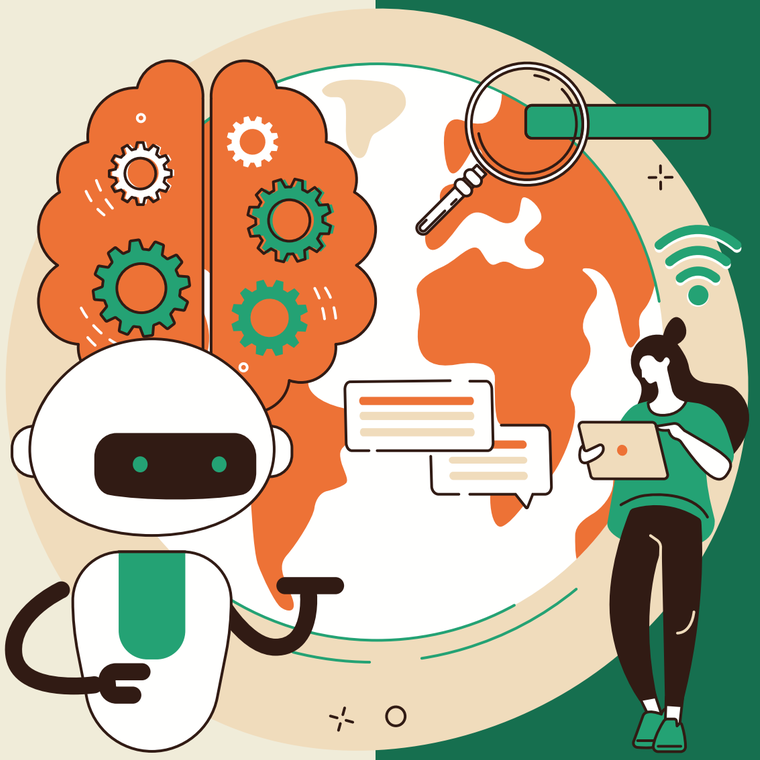

KESIMPULAN

- Pipeline data berhasil dibangun menggunakan AWS (S3, EC2, dan IAM) yang mendukung proses pengolahan data secara terintegrasi dari penyimpanan, pemrosesan, hingga visualisasi.
- Hasil analisis menunjukkan kategori tidak puas mendominasi, dengan rating rendah (1) paling tinggi dan rata-rata rating berada di kisaran 2–3 yang cenderung fluktuatif.
- Visualisasi data memperjelas pola kepuasan pengguna, di mana ulasan negatif didominasi kata seperti lama dan buruk, sedangkan ulasan positif didominasi cepat dan ramah.
- Penggunaan AWS terbukti efektif dalam mendukung proses analisis data yang fleksibel, terstruktur, dan mudah dikembangkan.
- Kendala pada penggunaan akun AWS dapat diatasi melalui kerja sama tim sehingga pipeline tetap berjalan dengan baik.

VIDEO DEMO PROGRAM & DASHBOARD

https://youtu.be/qvPVgMWu82s

https://public.tableau.com/shared/CGJ3PY3MN?:display_count=n&:origin=viz_share_link

TERIMA KASIH